

Guida Teorico-Pratica di Statistica con R

Per iniziare il tuo progetto, dovrai scegliere liberamente un dataset estraendolo da siti come Kaggle, UCI Machine Learning Repository, dati.gov.it o IstatData. In R, puoi caricare i tuoi dati tipicamente usando funzioni come `read.csv()`. Supponiamo per la guida che il tuo vettore di dati (una singola colonna o variabile quantitativa/qualitativa) si chiami `x`.

1 Costruzione della Tabella delle Frequenze

Teoria

Per analizzare i dati, è utile raggrupparli e contare quante volte compare ogni modalità.

- **Frequenza assoluta (f_i):** numero di volte in cui una certa modalità (valore) si presenta nel campione.
- **Frequenza assoluta cumulativa (F_i):** numero di dati con valore minore o uguale a una certa modalità.
- **Frequenza relativa (p_i):** il rapporto tra frequenza assoluta e ampiezza totale del campione ($p_i = f_i/n$).
- **Frequenza relativa cumulativa (P_i):** la somma delle frequenze relative per i valori minori o uguali a una certa modalità.

Applicazione in R

```
1 # Frequenze assolute
2 freq_assolute <- table(x)
3
4 # Frequenze assolute cumulative
5 freq_ass_cum <- cumsum(freq_assolute)
6
7 # Frequenze relative
8 freq_relative <- prop.table(freq_assolute)
9
10 # Frequenze relative cumulative
11 freq_rel_cum <- cumsum(freq_relative)
12
13 # Unione in un'unica tabella
14 tabella_frequenze <- cbind(freq_assolute, freq_ass_cum, freq_relative,
15                             freq_rel_cum)
16 print(tabella_frequenze)
```

2 Rappresentazione Grafica della Distribuzione

Teoria

A seconda del tipo di dati (qualitativi, quantitativi discreti o continui) si usano grafici diversi. Tra i più comuni ci sono il grafico ad aste (linee verticali che indicano le frequenze), grafico a linee (spezzata), grafico a barre (rettangoli), grafico a torta (settori circolari con angolo proporzionale alla frequenza) e istogramma (per dati raggruppati in classi di valori contigui).

Applicazione in R

```
1 # Grafico a barre
2 barplot(freq_assolute, main="Grafico a Barre", xlab="Modalit ", ylab="
  Frequenze")
3
4 # Grafico a torta
5 pie(freq_assolute, main="Grafico a Torta")
6
7 # Istogramma (ideale per dati quantitativi continui)
8 hist(x, main="Istogramma", xlab="Classi", ylab="Frequenze", col="
  lightblue")
```

3 Indici di Posizione (o di Tendenza Centrale)

Teoria

Questi indici sintetizzano i dati in un solo valore numerico.

- **Media campionaria** ($\bar{x}$): media aritmetica dei dati. Risente molto di valori eccezionalmente alti o bassi.
- **Mediana campionaria** ($\tilde{x}$): valore centrale dei dati riordinati in senso crescent. Se i dati sono pari, è la media dei due valori centrali. Non è influenzata dai valori anomali.
- **Moda campionaria** ($\hat{x}$): unico valore con frequenza massima (se esiste).

Applicazione in R

```
1 # Media
2 media <- mean(x, na.rm=TRUE)
3
4 # Mediana
5 mediana <- median(x, na.rm=TRUE)
6
7 # Moda (R non ha una funzione base, si calcola così:)
8 tab_sort <- sort(table(x), decreasing=TRUE)
9 moda <- as.numeric(names(tab_sort))
```

4 Indici di Variabilità (o di Dispersione)

Teoria

Valutano quanto i dati sono dispersi attorno ai valori tipici.

- **Varianza campionaria (s^2):** media dei quadrati delle distanze dei dati dalla media, divisa per $n - 1$ per ragioni tecniche.
- **Deviazione standard campionaria (s):** la radice quadrata della varianza campionaria.
- **Scarto medio assoluto (s_a):** media aritmetica degli scarti assoluti dalla media campionaria.
- **Ampiezza del campo di variazione (Range, w):** differenza tra il valore massimo e il minimo.
- **Coefficiente di variazione (cv):** rapporto tra la deviazione standard e la media ($cv = s/\bar{x}$). Misura la variabilità in modo indipendente dall'unità di misura (adimensionale).

Applicazione in R

```
1 n <- length(na.omit(x))
2
3 # Varianza campionaria (var in R divide gi per n-1)
4 varianza <- var(x, na.rm=TRUE)
5
6 # Deviazione standard campionaria
7 dev_standard <- sd(x, na.rm=TRUE)
8
9 # Scarto medio assoluto
10 scarto_medio_ass <- mean(abs(x - mean(x, na.rm=TRUE)), na.rm=TRUE)
11
12 # Ampiezza del campo di variazione
13 ampiezza_range <- max(x, na.rm=TRUE) - min(x, na.rm=TRUE)
14
15 # Coefficiente di variazione
16 coeff_var <- dev_standard / mean(x, na.rm=TRUE)
```

5 Indici di Forma

Teoria

Misurano caratteristiche della forma della distribuzione e sono adimensionali.

- **Indice di asimmetria (γ , Skewness):** Stabilisce se i dati hanno simmetria centrale. Se $\gamma > 0$ la distribuzione ha una coda lunga a destra (asimmetria positiva); se $\gamma < 0$ ha una coda a sinistra (asimmetria negativa).
- **Indice di curtosi (k):** Determina l'appiattimento. Se $k > 0$ la distribuzione è leptocurtica (eccesso di dati al centro), se $k < 0$ è platicurtica (carenza al centro), se $k = 0$ è simile a una normale (normocurtica). La formula prevede la sottrazione di un fattore 3.

Applicazione in R

Poiché le librerie base di R non hanno funzioni integrate, possiamo applicare direttamente le formule dei tuoi appunti:

```
1 # Asimmetria
2 asimmetria <- sum((x - mean(x))^3) / (n * sd(x)^3)
3
4 # Curtosi
5 curtosi <- (sum((x - mean(x))^4) / (n * sd(x)^4)) - 3
```

6 Quartili e Box Plot

Teoria

- **Quartili:** Dividono i dati ordinati in quattro blocchi da 25% l'uno. Il primo quartile (Q_1) corrisponde al 25-esimo percentile, il secondo (Q_2) è la mediana (50%), il terzo (Q_3) è il 75-esimo percentile.
- **Box Plot:** È uno strumento grafico basato sui quartili. Consiste in un rettangolo i cui estremi sono Q_1 e Q_3 , con una linea interna per Q_2 . Aiuta anche a identificare rapidamente la variabilità (scarto interquartile) e la presenza di outlier (dati anomali molto distanti dagli altri).

Applicazione in R

```
1 # Quartili (Q1, Mediana, Q3)
2 quartili <- quantile(x, probs=c(0.25, 0.50, 0.75), na.rm=TRUE)
3 print(quartili)
4
5 # Box plot
6 boxplot(x, main="Box Plot dei dati", col="lightgreen")
```

7 Dati Bivariati

Teoria

Questa analisi si applica quando hai coppie di dati (x_i, y_i) su cui ipotizzi una relazione.

- **Diagramma a dispersione:** Rappresentazione grafica sul piano cartesiano. Permette di osservare in modo grossolano se a valori alti di x corrispondono valori alti o bassi di y .
- **Coefficiente di correlazione campionario (r):** È un indice quantitativo adimensionale tra -1 e 1. Se $|r| = 1$ vi è correlazione lineare perfetta, se $|r|$ è vicino a 0,8 è molto intensa, e se è attorno a 0,3 è molto debole.

Applicazione in R

Supponendo tu abbia due variabili (es. due colonne del tuo dataset), x e y :

```
1 # Diagramma a dispersione (Scatter plot)
2 plot(x, y, main="Diagramma a dispersione", xlab="Variabile X", ylab="
  Variabile Y", pch=19)
3
4 # Coefficiente di correlazione campionario
5 correlazione <- cor(x, y, use="complete.obs")
6 print(correlazione)
```

Con questa guida teorico-pratica, sarai in grado di scrivere uno script R lineare e ordinato, e soprattutto potrai commentare adeguatamente ogni output basandoti sulle nozioni teoriche come richiesto dalle specifiche del tuo esame. Buon lavoro sul progetto!