

1. Tabella delle Frequenze

Per organizzare un campione di ampiezza n (ovvero contenente n dati), si considerano i valori distinti assunti dai dati, chiamati modalità (solitamente ordinate in senso crescente), e si contano le relative presenze.

- **Frequenza assoluta** (f_i): rappresenta il numero esatto di volte in cui una specifica modalità compare all'interno del campione.
- **Frequenza assoluta cumulativa** (F_i): è la somma delle frequenze assolute della modalità considerata e di tutte quelle precedenti. In pratica, indica quanti dati nel campione hanno un valore minore o uguale a quella specifica modalità.
- **Frequenza relativa** (p_i): si ottiene dividendo la frequenza assoluta per l'ampiezza totale del campione ($p_i = \frac{f_i}{n}$). Fornisce il "peso" o la proporzione di quella modalità ed è sempre un valore compreso tra 0 e 1.
- **Frequenza relativa cumulativa** (P_i): è la somma delle frequenze relative fino alla modalità considerata. Può essere calcolata anche dividendo la frequenza assoluta cumulativa per n ($P_i = \frac{F_i}{n}$).

2. Rappresentazione Grafica

I risultati si espongono graficamente per visualizzarne subito aspetti come la simmetria o il grado di concentrazione. I grafici richiesti nel progetto includono:

- **Grafico ad aste:** traccia linee verticali sull'asse delle ordinate corrispondenti alla frequenza assoluta di ciascun valore riportato sulle ascisse.
- **Grafico a linee** (o polygon graph): i punti che rappresentano le frequenze vengono uniti tramite una spezzata.
- **Grafico a barre:** utilizza dei rettangoli, dove l'altezza rappresenta la frequenza.
- **Grafico a torta:** particolarmente utile per dati qualitativi, suddivide un cerchio in settori circolari, dove l'angolo al centro di ogni "fetta" è proporzionale alla sua frequenza.
- **Istogramma:** se il numero di modalità è troppo elevato, i dati possono essere raggruppati in intervalli chiamati classi. Il grafico a barre delle frequenze di queste classi prende il nome di istogramma.

3. Indici di Posizione (Tendenza Centrale)

Questi indici sintetizzano i dati osservati con un solo valore rappresentativo.

- **Media campionaria** ($\bar{x}$): è la media aritmetica, calcolata come la somma di tutti i dati divisa per l'ampiezza del campione n . Risente sensibilmente di valori eccezionalmente alti o bassi (outlier).
- **Mediana campionaria** ($\tilde{x}$): è il valore centrale che si ottiene dopo aver riordinato i dati in ordine crescente. Se il numero di dati n è dispari, è esattamente il valore al centro; se n è pari, si calcola come media aritmetica dei due valori centrali. A differenza della media, non è influenzata dai dati estremi.
- **Moda campionaria** ($\hat{x}$): corrisponde all'unico valore (o ai valori, nel caso di distribuzioni

bi/multimodali) che ha la frequenza massima nel campione.

4. Quartili e Box Plot

I percentili sono valori che indicano la posizione dei dati rispetto a certe percentuali. I quartili dividono il campione ordinato in quattro parti uguali, ciascuna contenente circa il 25% dei dati.

- Il **primo quartile** (Q_1) è il 25-esimo percentile.
- Il **secondo quartile** (Q_2) coincide con la mediana campionaria (50-esimo percentile).
- Il **terzo quartile** (Q_3) è il 75-esimo percentile.
- Il **Box Plot** è uno strumento grafico costruito usando il minimo, il massimo e i quartili. È formato da una linea orizzontale che va dal dato minore al dato maggiore (l'ampiezza totale, o range), e da un rettangolo centrale che va dal primo (Q_1) al terzo quartile (Q_3), detto scarto interquartile, tagliato da una linea verticale all'altezza della mediana (Q_2). È molto utile per individuare facilmente dati anomali (detti outlier) che si discostano significativamente dal resto dei dati.

5. Indici di Variabilità (Dispersione)

Indicano quanto i dati sono concentrati o “sparpagliati” attorno alla media campionaria, offrendo una misura per valutare l'affidabilità degli indici di posizione.

- **Varianza campionaria** (s^2): si calcola prendendo le differenze tra ciascun dato e la media ($\bar{x}$), elevandole al quadrato, sommandole tutte e dividendo il risultato per $n - 1$.
- **Deviazione standard campionaria** (s): è semplicemente la radice quadrata della varianza campionaria. È tanto più grande quanto più i dati sono eterogenei tra loro.
- **Scarto medio assoluto** (s_a): rappresenta la media aritmetica degli scarti (presi in valore assoluto) tra ciascun dato e la media campionaria.
- **Ampiezza del campo di variazione** (w): è la differenza tra il dato dal valore massimo e quello dal valore minimo all'interno del campione.
- **Coefficiente di variazione** (cv): calcolato dal rapporto tra la deviazione standard (s) e la media campionaria ($\bar{x}$). È un indice privo di unità di misura, essenziale per paragonare direttamente la variabilità tra insiemi di dati aventi scale o unità di misura differenti.

6. Indici di Forma

Forniscono informazioni relative al profilo visivo che la distribuzione assume quando rappresentata (es. tramite un istogramma).

- **Indice di Asimmetria** (Skewness, γ): valuta la simmetria centrale. Se $\gamma > 0$ la distribuzione ha una “coda” più lunga verso i valori alti a destra (asimmetria positiva); se $\gamma < 0$, la coda è verso sinistra.
- **Indice di Curtosi** (k): serve a stabilire l'appiattimento della distribuzione. Se l'indice $k > 0$, la distribuzione si dice leptocurtica (c'è un eccesso di dati nelle porzioni centrali); se $k < 0$, si definisce platicurtica (carenza di dati centrali) e risulta più “schiacciata”. Se $k = 0$, la forma assomiglia molto alla classica distribuzione “a campana” o normale.

7. Analisi Bivariata (Due variabili)

Infine, il progetto richiede l'analisi di dati bivariati, ovvero coppie di valori dipendenti tra loro (es. altezza e peso, oppure numero di abitanti e produzione di rifiuti) per i quali vogliamo capire se e come interagiscono.

- **Diagramma a dispersione** (Scatterplot): è un grafico sul piano cartesiano dove ogni singola coppia di dati del campione diventa un punto nello spazio, identificato dalle coordinate (x_i, y_i) . Osservandolo “ad occhio”, è il primo strumento per capire se ci sia una qualche logica/correlazione nei dati.
- **Coefficiente di correlazione campionario** (r): è l'indice numerico (sempre compreso tra -1 e 1) che quantifica la forza della relazione tra le due grandezze. Se $r > 0$, c'è correlazione positiva (valori elevati di x corrispondono a valori elevati di y). Se $r < 0$, c'è correlazione negativa (al crescere di x , decresce y). Se il valore assoluto di r è vicino a 1, i punti seguono quasi perfettamente l'andamento di una linea retta (correlazione molto intensa); se è vicino allo 0, non c'è una chiara correlazione lineare.